#### TASK目标:

本次TASK具体要求如下:

- (1) 构建一个你自己的CNN模型用来对cifar10数据进行训练,将精度与案例中的精度对比,看看效果如何?
- (2) 对所有程序做详细注释,以确认你的理解正确;
- (3) 请详细计算并解释你所建立的CNN模型的参数个数。

## In [1]:

```
from PIL import Image
from glob import glob
import numpy as np
from keras.utils import to_categorical
from matplotlib import pyplot as plt
from sklearn.model_selection import train_test_split
from keras.layers import Dense, Flatten,Input,Activation,Conv2D,MaxPooling2D,BatchNormalization
from keras import Model

I was a simport before the provided and the provi
```

## In [2]:

```
import tensorflow as tf
from tensorflow.keras import datasets, Sequential, layers,metrics
```

# In [29]:

```
filename = 'F:\\大三(上)\\深度学习\\TASK3.2: Case Study: Cifar10数据训练\\cifar-10-batches-py'

def load_file(filename):
    with open(filename,'rb') as fo:
    data = pickle.load(fo,encoding='latin1')
    return data
```

# 构建自己的模型

#### In [13]:

```
(X_train, y_train), (X_test, y_test) = datasets.cifar10.load_data() #导入数据
```

# In [14]:

```
print('图像数据格式:', X_train.shape)
print("训练集:%2.0f",测试集:%2.0f"%(X_train.shape[0], X_test.shape[0])) # 转化成矩阵
```

图像数据格式: (50000, 32, 32, 3) 训练集: 50000, 测试集: 10000

#### In [15]:

X\_train[0][:5, :, 1] # 图片矩阵中的第一条记录,显示R矩阵前5行

#### Out[15]:

```
array([[ 62, 46, 48, 54, 73, 91, 107, 110, 117, 120, 103, 99, 115, 112, 105, 97, 106, 106, 97, 113, 112, 105, 105, 108, 120, 131, 136, 129, 130, 132, 125, 124],
```

```
[20, 0, 8, 27, 51, 82, 89, 86, 87, 79, 70, 67, 70, 74, 70, 72, 79, 71, 69, 89, 92, 85, 89, 82, 79, 89, 91, 94, 96, 88, 83, 87],
[24, 7, 27, 50, 72, 92, 93, 82, 77, 78, 79, 75, 73, 92, 87, 92, 89, 85, 79, 85, 95, 96, 102, 90, 89, 89, 92, 105, 94, 84, 84, 73],
[25, 20, 54, 63, 70, 74, 72, 62, 68, 84, 90, 75, 77, 105, 91, 84, 76, 76, 87, 81, 92, 99, 99, 93, 86, 91, 90, 93, 90, 87, 85, 62],
[32, 32, 65, 79, 77, 77, 78, 74, 72, 88, 89, 68, 71, 83, 78, 68, 65, 74, 80, 80, 93, 106, 95, 98, 92, 84, 79, 79, 67, 57, 47, 42]], dtype=uint8)
```

# In [33]:

```
fig = plt.figure(figsize = (20, 5)) #构建画布

for i in range(20): #展示20张图片

ax = fig.add_subplot(2, 10, i + 1, xticks = [], yticks = [])
ax.imshow(X_train[i])

#y_train[:20].reshape(2, 10)
```









































### In [17]:

```
# 对因变量做处理
from keras.utils import np_utils

y_train = np_utils.to_categorical(y_train) #将整型的类别标签转为onehot编码
y_test = np_utils.to_categorical(y_test) #将整型的类别标签转为onehot编码

from keras.models import Sequential
from keras.layers import *
from keras.backend import *
```

#### In [18]:

```
inoder.compile(loss = categorical crossentropy,
                                          #狄入凶效
       optimizer = 'adam', metrics = ['accuracy']) #优化器;准确率
model.fit(X train, y train, epochs = 10) #调用模型求解
                           #输入数据和标签,输出损失和精确度.
model.evaluate(X test, y test)
```

Model: "sequential"

Layer (type)	Output Shape	Param #	
conv2d (Conv2D)	(None, 30, 30	, 32)       896	
max_pooling2d (Max	xPooling2D) (None,	15, 15, 32)	0
flatten (Flatten)	(None, 7200)	0	
dense (Dense)	(None, 128)	921728	
dense_1 (Dense)	(None, 10)	1290	

Total params: 923,914 Trainable params: 923,914 Non-trainable params: 0

Epoch 1/10

Epoch 2/10 Epoch 3/10 Epoch 4/10 Epoch 5/10

Epoch 6/10

Epoch 7/10

Epoch 8/10

Epoch 9/10

Epoch 10/10

#### Out[18]:

[2.4223148822784424, 0.5156000256538391]

卷积层: 输入是3通道, 输出是32通道, 每输出一个通道需要消耗:共有32个输出通道, 所以消耗了896个参数.

最大池化层:输出的还是32通道,不需要任何参数,

flatten层: 将上一层的32通道矩阵拉直成一个长向量, 输出的是15x15x32=7200的向量, 不需要消耗任何参数.

输出层(dense层): 输入为7200维的向量, 分别输出为10维和2维向量. 消耗的参数为: 921728+1290=923018 个参数.

. 1

合计: 共消耗了: 923914个参数

#### In [20]:

```
from keras.models import Sequential
from keras.layers import Dense, Dropout, Activation, Flatten
from keras.layers import Conv2D, MaxPooling2D
import keras
from keras.callbacks import ModelCheckpoint
```

#### In [21]:

```
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[0., 1., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[0., 1., 0., 0., 0., 0., 0., 0., 0., 0.]
[[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.],
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[0., 1., 0., 0., 0., 0., 0., 0., 0., 0.]
[[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.],
[1., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[0., 1., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
```

[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]

```
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.,
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.],
[0., 1., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.],
[0., 1., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.],
[1., 0., 0., 0., 0., 0., 0., 0., 0.]
[0., 1., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.],
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[0., 1., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.],
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[0., 1., 0., 0., 0., 0., 0., 0., 0., 0.]
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.]
[[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.],
```

[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.], [1., 0., 0., 0., 0., 0., 0., 0., 0., 0.], [0., 1., 0., 0., 0., 0., 0., 0., 0., 0.]

```
[1., 0., 0., 0., 0., 0., 0., 0., 0., 0.],

[1., 0., 0., 0., 0., 0., 0., 0., 0.],

[1., 0., 0., 0., 0., 0., 0., 0., 0.],

[1., 0., 0., 0., 0., 0., 0., 0., 0.],

[1., 0., 0., 0., 0., 0., 0., 0., 0.]]

[1., 0., 0., 0., 0., 0., 0., 0., 0.]]], dtype=float32)
```

# In [22]:

```
#建立基于keras的cnn模型
model = Sequential()
#卷积==>卷积==>最大池化
model.add(Conv2D(32, (3, 3), padding = 'same',
         input shape = X train1.shape[1:])) # 第一层需要指定数据格式
model.add(Activation('relu'))
model.add(Conv2D(32, (3, 3)))
model.add(Activation('relu'))
model.add(MaxPooling2D(pool_size = (2, 2)))
model.add(Dropout(0.25))
#卷积==>卷积==>最大池化
model.add(Conv2D(64, (3, 3), padding = 'same'))
model.add(Activation('relu'))
model.add(Conv2D(64, (3, 3)))
model.add(Activation('relu'))
model.add(MaxPooling2D(pool_size = (2, 2)))
model.add(Dropout(0.25))
#将数据展平
model.add(Flatten())
model.add(Dense(512))
model.add(Activation('relu'))
model.add(Dropout(0.5))
model.add(Dense(10))
model.add(Activation('softmax'))
model.summary()
```

### Model: "sequential\_1"

Layer (type)	Output Shape	Param #	
conv2d_1 (Conv2D)	(None, 32, 32, 32	) 896	
activation (Activation)	(None, 32, 32, 32)	0	
conv2d_2 (Conv2D)	(None, 30, 30, 32	9248	
activation_1 (Activation	(None, 30, 30, 32)	0	
max_pooling2d_1 (Max	xPooling2 (None, 15, 1	5, 32) 0	
dropout (Dropout)	(None, 15, 15, 32)	0	
conv2d_3 (Conv2D)	(None, 15, 15, 64	) 18496	
activation_2 (Activation	(None, 15, 15, 64)	0	
conv2d_4 (Conv2D)	(None, 13, 13, 64	) 36928	
activation_3 (Activation	(None, 13, 13, 64)	0	
	Daaling (Nana C. C.	0.4)	

max_poomigea_e (Maxi	00migz (140mo, 0, 0,	04)	
dropout_1 (Dropout)	(None, 6, 6, 64)	0	
flatten_1 (Flatten) (	None, 2304)	0	
dense_2 (Dense)	(None, 512)	1180160	
activation_4 (Activation)	(None, 512)	0	
dropout_2 (Dropout)	(None, 512)	0	
dense_3 (Dense)	(None, 10)	5130	
activation_5 (Activation)	(None, 10)	0	

Total params: 1,250,858 Trainable params: 1,250,858 Non-trainable params: 0

\_\_\_\_\_

卷积层1: 输入是32通道, 输出是32通道, 每输出一个通道需要消耗:896个参数.

卷积层2: 输入是30通道, 输出是32通道, 每输出一个通道需要消耗:9248个参数.

最大池化层1:输出的还是32通道,不需要任何参数.

dropout层:输出的还是32通道,不需要任何参数.

卷积层3: 输入是15通道, 输出是64通道, 每输出一个通道需要消耗:18496个参数.

卷积层4: 输入是13通道, 输出是64通道, 每输出一个通道需要消耗:36928个参数.

最大池化层2:输出的还是64通道,不需要任何参数,

flatten层: 将上一层的64通道矩阵拉直成一个长向量, 输出的是72304的向量, 不需要消耗任何参数.

dropout 2层: 输出的还是512通道, 不需要任何参数.

输出层(dense层): 输入为512维的向量, 输出为10维向量. 消耗的参数为:1180160+5130=1185290个参数.

合计: 共消耗了: 1,250,858个参数.

#### In [34]:

Epoch 1/10

```
model.compile(loss = 'categorical_crossentropy', #损失函数
optimizer = 'adam', metrics = ['accuracy']) #优化器;准确率
model.fit(X_train, y_train, epochs = 10) #调用模型求解
model.evaluate(X_test, y_test)
```

# 案例模型

## In []:

```
images = glob("cifar10/*") # 导入数据
N=len(images) #定义图片长度
imsize=32 #设置随机种子
```

# In [3]:

### In [4]:

```
unique=list(set(Y))
DICT={}
for i in range(len(unique)): DICT[unique[i]]=i
YY=np.zeros(N)
for i in range(N):
YY[i]=DICT[Y[i]] #数据标准化
```

# In [5]:

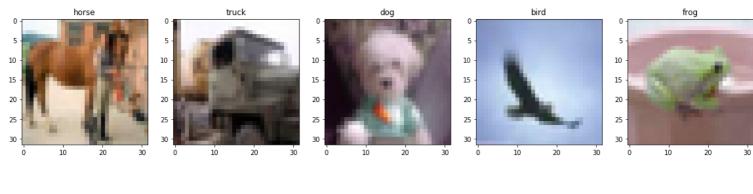
```
DICT #查看数据类别
```

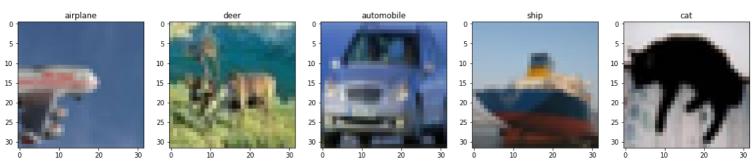
# Out[5]:

```
{'horse': 0,
'truck': 1,
'dog': 2,
'bird': 3,
'frog': 4,
'airplane': 5,
'deer': 6,
'automobile': 7,
'ship': 8,
'cat': 9}
```

#### In [6]:

```
#构建画布
fig,ax=plt.subplots(2,5)
fig.set_figwidth(20)
fig.set_figheight(10)
ax=ax.flatten()
for i in range(len(ax)):
  Im=X[YY==i][0]
  ax[i].imshow(Im)
                             #输出标准化格式图片数据
  ax[i].set_title(unique[i])
                                                                            bird
                                                                                                   frog
```





# In [7]:

#类别向量转为多分类矩阵 Y=to categorical(YY) X0,X1,Y0,Y1=train\_test\_split(X,Y,test\_size=0.5,random\_state=1) # 拆分数据集

# In [35]:

```
input size=[imsize,imsize,3]
                                #设置空矩阵
input layer=Input(input size)
                                #输出
x=input layer
x=Conv2D(100,[2,2],padding = "same", activation = 'relu')(x)
x = MaxPooling2D(pool\_size = [2,2])(x)
x=Conv2D(100,[2,2],padding = "same", activation = 'relu')(x)
x = MaxPooling2D(pool\_size = [2,2])(x)
x=Conv2D(100,[2,2],padding = "same", activation = 'relu')(x)
x = MaxPooling2D(pool\_size = [2,2])(x)
x=Flatten()(x)
x=Dense(10,activation='softmax')(x)
output_layer=x
model=Model(input_layer,output_layer) # 建立模型
                               #输出模型各层的参数状况
model.summary()
```

### Model: "model\_14"

Layer (type)	Output Shape	Param #	
input_14 (InputLayer)	(None, 32, 32, 3)	0	
conv2d_44 (Conv2D)	(None, 32, 32, 1	00) 1300	
max pooling2d 44 (M	laxPooling (None. 16.	16. 100) 0	

0100
0
100
0
)

输入层:输入的是3通道的图片,不消耗任何参数.

卷积层 44: 输入是3通道, 输出是100通道, 每输出一个通道需要消耗: 1300个参数.

最大池化层 44: 输出的还是100通道, 不需要任何参数.

卷积层 45: 输入是3通道, 输出是100通道, 每输出一个通道需要消耗: 40100个参数.

最大池化层 45: 输出的还是100通道, 不需要任何参数.

卷积层 46: 输入是3通道, 输出是100通道, 每输出一个通道需要消耗: 40100个参数.

最大池化层 46: 输出的还是100通道, 不需要任何参数.

flatten层: 将上一层的100通道矩阵拉直成一个长向量, 输出的是1600的向量, 不需要消耗任何参数.

输出层(dense层): 输入为100维的向量, 输出为10维向量. 消耗的参数为:16010个参数.

Epoch 6/10
30000/30000 [=================================
ss: 0.8638 - val_accuracy: 0.7027
Epoch 7/10
. 30000/30000 [=================================
oss: 0.8632 - val_accuracy: 0.7034
Epoch 8/10
30000/30000 [=================================
oss: 0.8630 - val_accuracy: 0.7040
Epoch 9/10
30000/30000 [=================================
oss: 0.8633 - val_accuracy: 0.7042
Epoch 10/10
30000/30000 [=================================
oss: 0.8633 - val_accuracy: 0.7033

# Out[38]:

<keras.callbacks.callbacks.History at 0x7f4c26e99290>

通过将自己建立的模型和案例模型进行对比,观察准确度,还是案例模型更胜一筹。

# In [ ]:

